

基于提升小波和深度学习的掌纹识别

赵丹丹, 潘新, 刘霞, 郝晓晶

(内蒙古农业大学计算机与信息工程学院, 内蒙古 呼和浩特 010018)

摘要: 针对从少量样本中学习图像本质特征的关键问题, 提出一种基于深度学习的二次特征提取的掌纹识别方法。采用提升小波与深度学习结合的思想, 将掌纹图像首先进行提升小波变换, 获取图像的局部细节信息作为深度置信网的输入, 然后通过自顶向下的无监督的训练和自底向上的有监督训练, 获得最优的网络参数, 最后进行分类预测。实验对比传统算法 (PCA, LBP) 以及基于像素级的 DBN 算法, 得到较高的识别率, 将提升小波获取的初始特征经过深度学习二次特征提取可有效地获取较稳的掌纹识别特征, 特别在样本较少的情况下, 优势尤为显著。

关键词: 深度学习; 提升小波; 深度置信网; 特征提取; 识别率

中图分类号: TP183 **文献标识码:** A

Palmprint Recognition Based on Lift Wavelet and Deep Learning

ZHAO Dan-dan, PAN Xin, Liu Xia, Gao Xiao-jing

(Inner Mongolia Agricultural University College of Computer and Information Engineering,
Hohhot Inner Mongolia 010018, China)

ABSTRACT: To solve the key problem for the extraction of essential features from a relatively small number of images, we proposed a new feature re-extraction method based on deep learning. Combining lifting wavelet with deep learning, we first used the proposed approach to employ lifting wavelet to convolve with the normalized palmprint images for the local details. Then, the lift wavelet training samples were put into the model for optimum parameters of the network through top-to-bottom unsupervised training and bottom-to-top supervised training. Finally, the lift wavelet test samples are identified as the corresponding label by the trained model. The experimental results demonstrate better performance of the proposed algorithm compared with traditional algorithms, such as LBP, PCA, and original DBN based on pixel level. Therefore, the re-extraction of DBN based on the initial characteristics gained by lift wavelet can effectively obtain the robust features of palmprint images, especially when there is a small number of training samples.

KEYWORDS: Deep learning; Lift wavelet; Deep belief nets; Feature extraction; Recognition rate

1 引言

掌纹识别是近几年来兴起的一种生物特征识别技术, 相比于虹膜、指纹、人脸等其他生物特征, 掌纹有很多自己独特的优势, 如采集方便、识别区域大、可靠性和精度高等, 在人机接口和身份认证等方面有着广泛的应用^[1]。

掌纹识别通过提取手掌纹理的特征信息来鉴别个人的身份。在识别过程中, 特征提取至关重要, 其直接影响到掌

纹识别结果的优劣。传统的掌纹特征提取方法主要分为基于掌纹结构特征、统计特征、子空间特征和编码特征四大类^[2]。卢光明和邬向前提出了基于特征掌的掌纹识别算法^[3,4]。Ling Lin等人结合PCA和启发式人工神经网络进行掌纹识别^[5]。Yi Pu等人提出了基于K-Means和SVM的掌纹识别方法^[6]。这些浅层方法^[7]在训练样本和计算单元有限的时候, 学习到的特征有限, 本文尝试以深层的方法来提取特征以完成识别。近年来, 深度学习的迅速发展引起了学术界和互联网界的重视, 并在图像识别、语音识别、自然语言识别等领域取得了不错的成绩。

2006年, 多伦多大学的Hinton等提出了基于深度信念网络 (Deep Belief Network, DBN) 的非监督逐层训练算法。受此启发, 学者们依次衍生出卷积神经网络、自编码网络等

基金项目: 国家自然科学基金 (61562067); 中国博士后科学基金项目 (201004800370, 201104179); 内蒙古高等学校研究基金 (NJZY13074, NJZY068); 内蒙古农业大学基金项目 (NDPYTD 210-9)

收稿日期: 2015-10-14 修回日期: 2016-03-23

深度学习模型。深度学习通过模拟人脑的分层视觉处理系统,组合低层的特征通过抽象和迭代,形成更抽象更有效的高层表示^[9],充分展示了其能从少数样本中学习数据本质特征的优良特性。不少文献显示卷积神经网络(Convolution Neural Network, CNN)在图像分类、识别等领域^{[10][11]}获得不错的结果。胡昭华用深度自编码网络(Autoencoder)实现了瑞士卷数据的重构^[12]。本文选用 DBN 这种被称为“第三代神经网络^[13]”的典型深度学习模型,模拟人类的分层视觉处理系统,通过自顶向下的非监督学习和自底向上的监督学习学习不同层次的抽象特征,整个训练过程中不依赖人工选择。DBN 已成功应用于很多领域,手写字体识别^[9]是最先应用的领域,文献^[14]成功应用于人体动作检测,人脸识别^[15]领域中有学者将传统算法如 LBP、Gabor 小波等传统算法与 DBN 结合取得了不错的识别效果,目前,掌纹识别领域尚未发现成功应用的实例。由于 DBN 的输入是一维向量模式,掌纹图像的局部细节特征就难以兼顾到^[16],并且如果直接以像素级的掌纹图像作为输入, DBN 模型还会因为光照、倾斜等不利因素学习到不良的特征,最终影响到识别结果。

提升小波是由贝尔实验室的 Sweldens, W 博士提出的^[17]。传统小波变换大多数在频域中构造,过程较复杂,而提升小波完全可以在空间域实现变换,不依赖于傅立叶变换,具有空间域局部性的特征,有利于细节特征的提取;而且提升小波算法简单、构造方法灵活、运算速度快、原位运算、占用内存较小,是一种快速有效的小波变换方法。本文将经过提升小波变换的小波特征作为 DBN 网络的输入,可有效避免上文所述深度学习遇到的难题。

考虑到深度学习模型的优缺点,本文创新性地提出通过提升小波处理掌纹图像,获取其局部细节性信息,并利用 DBN 网络进一步自动抽取更高层、更抽象、更有效的掌纹特征的方法,充分地利用了提升小波的优势并弥补了深度学习模型的缺陷。在北京交通大学的掌纹库上进行试验,与传统的 PCA、LBP 算法相比,本文算法所提取的掌纹特征判别性更强,更有效地表示掌纹信息,对测试样本有更准确的分类预测。

2 提升小波和深度学习

2.1 提升小波

传统的小波变换是在欧式空间内通过基底的平移和伸缩来构造小波基,为信号处理和工程应用等领域多有应用。但是并不适合在非欧式空间中应用。1995 年,贝尔实验室的 Sweldens 博士提出利用一种全新的在时域中采用提升方案构造小波,被后人称为“第二代小波变换”^[18]。

提升算法的基本思想是用多项式插补来获取信号的高频分量(s 系数),之后通过构建尺度函数来获取信号的低频分量(d 系数)。提升的基本含义是通过一个基本小波,根据提升变换逐步构建出一个新的、具有更好性质的小波。一般提升小波变换有 3 个步骤:分裂;预测;修正。具体实现步骤

如图 1 所示。




图 1 提升算法的实现步骤

1) 分裂

分裂又称惰性小波变换。将输入数据 S_n 分为两个互不相交的子集和,每个子集的长度是原子集的一半。假定数据间有相关性,按奇偶序号进行间隔采样,即可得到两个互不相交的子集,即将数据分成奇、偶子集。

$$F(S_n) = (S_{n-1}, d_{n-1}) \quad (1)$$

2) 预测

将输入数据 S_n 按式(1)进行间隔采样,即将数据分成奇、偶子集。利用奇偶序列之间的相关性,用一个序列(通常是偶数序列 S_{n-1})和预测值 $P(S_{n-1})$ 去预测另一个序列(奇数序列 d_{n-1}),奇序列的实际值与预测值的差值称为细节系数或者小波系数,反映了两者之间的逼近程度。虽然序列 d_{n-1} 不可能由序列 S_{n-1} 准确预测,但是预测值可以做到很接近奇数序列 d_{n-1} ,所以用预测值 $P(S_{n-1})$ 和 d_{n-1} 的差来代替原来的 d_{n-1} 。

本文采用计算简单的 Haar 小波作为提升小波的小波基进行预测。用偶数序列样本值 even 去预测奇数序列样本值 odd,奇数列样本值和预测值之间的差 d_{n-1} 反映了两者之间的逼近程度,一般称为细节信息。预测过程如下,其中偶数序列样本 even 为预测函数 $P(\cdot)$ 的参数:

$$d_{n-1} = odd_{n-1} - P(even_{n-1}) \quad (2)$$

这样 d_{n-1} 比原来的 odd_{n-1} 包含更少的信息,因此可以用更小的子集 S_{n-1} 和 d_{n-1} 来代替原信号集 S_n 。根据式(1)(2),重复分解和预测的过程,可以得出经 n 步预测后的原信号集: $\{S_n, d_{n-1}, \dots, S_1, d_1\}$ 。

3) 修正

预测之后,经过分裂步骤产生子集的某些性质(如平均值)和原始数据的可能不一致。因此我们采用一个更新过程,来保持原始数据的整体特征。更新过程如下

$$S_{n-1} = even_j + U(d_{n-1}) \quad (3)$$

与 Mallat 算法相比,利用提升方案构造小波的计算方法简单,速度快,适用于自适应、非线性、非奇异采样和整数到证书的变换^[18],并不依赖于傅立叶变换,直接在时域或空域分析问题。经过 Daubechies 和 Sweldens 证明,所有能够用 Mallat 算法快速实现的离散小波变换都可以用提升小波方法来实现,即能构造所有传统小波。提升小波变换既继承了传统小波变换的优点,又克服了它时频局部化的局限性。本文

采用提升小波变换来提取掌纹图像的局部细节特征。

2.2 深度置信网 (DBN)

深度学习的概念源自机器学习,神经网络中含有多隐层的多层感知器 (multilayer perception, MLP) 其实就是一种深度学习结构。深度学习结构通过组织低层的特征来形成更加抽象的高层表示^[16]。Hinton 等人提出的 DBN 结构,是由受限玻尔兹曼机 (RBM, restricted boltzman machines) 组成的。

2.2.1 RBM

玻尔兹曼机实质是个二部图,一层为可视层 v (v_1, v_2, \dots, v_m), 一层为隐藏层 h (h_1, h_2, \dots, h_n), RBM 为受限的玻尔兹曼机,每层的节点之间相互独立,为使得训练更容易,令每层的节点随机的二值化,即为 0 或 1。其结构如图 2 所示。




图 2 RBM 结构

RBM 的每层节点满足玻尔兹曼分布,从能量函数的出发,输入层或可视层 (v) 和输出层或隐含层 (h) 之间联合组态的能量可以表示为

$$E(v, h; \theta) = -v^T W h - b^T v - c^T h \\ = - \sum_{i=1}^n \sum_{j=1}^m w_{ij} v_i h_j - \sum_{i=1}^m b_i v_i - \sum_{j=1}^n c_j h_j \quad (4)$$

(4) 式显示每个可视节点和隐藏节点之间连接结构的能量。其中: $\theta = \{W, b, c\}$ 是 RBM 模型的参数, w_{ij} 为可视层节点 v_i 和隐藏层节点 h_j 间的权值, b_i 和 c_j 为相应的偏置项。

在 RBM 模型中,同层节点之间是条件独立的,不存在连接,即:

$$P(h | v) = \prod_j P(h_j | v) \quad (5)$$

$$P(v | h) = \prod_i P(v_i | h) \quad (6)$$

由 (5) 可知,在可视层 v 已知的基础上,可以计算得到隐层节点 h_j 为 1 的概率为:

$$P(h_j = 1 | v) = [1 + \exp(- \sum_i w_{ij} v_i - c_j)]^{-1} \quad (7)$$

同理由 (6) 可知,在隐层 h 已知的基础上,可视层节点 v_i 为 1 的概率为:

$$P(v_i = 1 | h) = [1 + \exp(- \sum_j w_{ij} h_j - b_i)]^{-1} \quad (8)$$

由于 RBM 是一种随机机器,所以用概率论来评价其性能。因此,为使其联合组态的能量最小,用极大似然法来求模型参数 θ 。把似然函数写成: $L(\theta | v) = \prod_p p(v)$, 对每个训

练样本采用 Gibbs 采样得到对应样本,结合对数似然概率 $\ln P(v)$ 的导数可以得到梯度的近似表达: $\frac{\partial \ln p(v)}{\partial w_{ij}}, \frac{\partial \ln p(v)}{\partial b_i}, \frac{\partial \ln p(v)}{\partial c_j}$,

这三个梯度,经过若干次对比散度 (Contrastive Divergence) 算法^{[19][20]}迭代,可以求出参数 $\theta = \{W, b, c\}$ 。

RBM 的训练过程如下:

输入 RBM 训练样本集

输出 参数 W, b, c

1) 初始化模型参数 $W = 0, b = c = 0$;

2) 在第 $t = (0, 1, \dots, K-1)$ 步中,先后采样 $h_j^{(t)} \sim p(h_j | v^{(t)})$, $v_i^{(t+1)} \sim p(v_i | h^{(t)})$

3) 根据采样值,按下列规则更新权值

$$\Delta w_{ij} \leftarrow \Delta w_{ij} + P(h_j = 1 | v^{(0)}) v_i^{(0)} - P(h_j = 1 | v^{(K)}) v_i^{(K)}$$

$$\Delta b_i \leftarrow \Delta b_i + v_i^{(0)} - v_i^{(K)}$$

$$\Delta c_j \leftarrow \Delta c_j + P(h_j = 1 | v^{(0)}) - P(h_j = 1 | v^{(K)})$$

2.2.2 DBN

DBN 是 Hinton 大师 2006 年提出的概率生成模型,由多层 RBM 叠加而成。它能够由简单到复杂、由低级到高级地学习输入数据的特征,输入数据作为第一层 RBM 的可视层的输入进行训练,第 i 层 RBM 的隐含层的输出,作为第 $i+1$ 层 RBM 的输入,最后一层 RBM 的输出作为整个 DBN 网络的输出。在做分类时,在顶层加一个逻辑回归层,本文采用 BP 网络进行回归,应用 SoftMax 回归对特征分类,从而得到输入数据的标签。DBN 的结构如图 3 所示。

DBN 的训练过程采用逐层训练的方法,每次只训练一层 RBM, RBM 层内进行无监督训练,抽象、迭代并调整自己的参数;训练完一层后,将该层的训练结果作为下一层 RBM 的输入;如此直至每一层 RBM 都训练完成,这个过程称预训练,预训练过程是无监督的。无监督训练完成后,再根据训练样本的标签,采用 BP 算法向下微调网络参数,微调过程是有监督的。

3 结合提升小波和深度学习的掌纹识别

如果直接以像素级的掌纹图像作为 DBN 的输入,模型能学习到掌纹图像中隐含的抽象特征,但是由于输入特征是图像的一维向量形式,深度模型对图像的局部细节特征学习到的不够。本文尝试以提升小波提取的小波特征作为模型输入,可以使得 DBN 能更有效地捕获掌纹图像的局部细节信息。

若 DBN 网络训练得不够好,则对输入的特征学习到的也就有限。反之,若训练良好,网络学习到的特征更能代表图像本身。因此,若 DBN 网络训练得不够好、参数没有达到全局最优,该网络用于分类甚至无法达到浅层网络的性能^[7]。无监督的训练虽然可以避免网络陷入局部最优,但是参数如何能调到最佳,依然难以控制。

本文通过提升小波和 DBN 来进行掌纹识别,如图 4 所

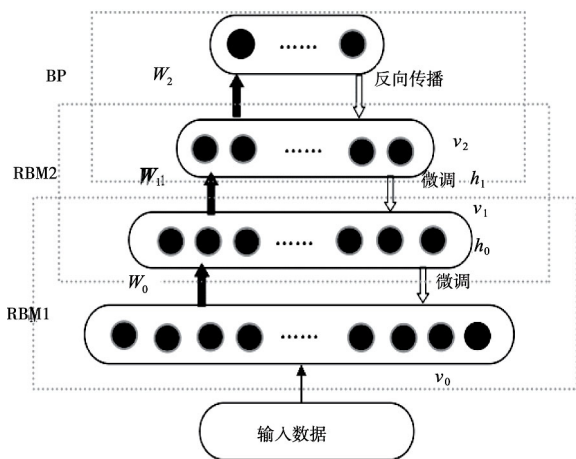


图3 DBN 结构

示。本文算法具体步骤如下:

- 1) 将训练样本和测试样本进行统一的预处理,裁剪、增强、归一化到 32×32 。
- 2) 对训练样本和测试样本分别进行提升小波变换,将提取的小波特征作为新的训练样本和测试样本。本文采用以 Haar 小波为基础的三层提升小波变换,所提取的小波特征和像素级掌纹特征维数相当。
- 3) 将 2) 中提取的训练样本的小波特征作为 DBN 模型的输入,进行自下而上无监督训练和自上而下有监督微调,尝试获取最优的网络参数。本文的 DBN 层数选为 2 层;两层学习率均为 0.0003,考虑到处理时间,RBM 的迭代次数均设置为 40。

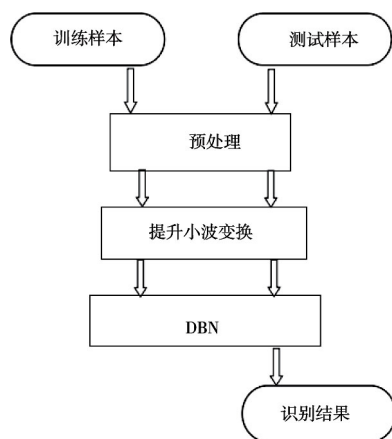


图4 基于提升小波和深度学习的掌纹识别

- 4) 将 2) 中提取的测试样本的小波特征输入经 3) 训练好的 DBN 网络,自底向上逐层地学习和抽取测试样本的抽象特征,并在网络的最顶层进行回归分类,获得测试样本的标签值,并计算识别率。

4 实验结果及分析

为验证本文算法的有效性,用北京交通大学的掌纹库做识别实验。实验前,所有的掌纹图像经过统一的定位、校准、剪切、归一化。实验的硬件配置为:3.20GHz 的 Intel(R) Core(TM) 4.00GB 内存,Window7 旗舰版操作系统。软件环境:MATLAB R2011a。

北京交通大学掌纹库共收集了 172 人的左右手的掌纹,存储了每个人的 10 张左手图片和 10 张右手图片,共 3640 个图片。为了方便实验,本文随机选取 50 个人的左右手图,即 100 类,每类 10 张图片,共 1000 张图片。文献^[22]指出,DBN 模型每批处理的图片至少应包含每类中的一张,因此,所有实验中, $batchsize$ 定为 100。在 DBN 的顶层用 Softmax 分类。由于图片的总类为 100,设置 DBN 模型的顶层输出层单元为 100,因此, DBN 的结构为 $1024 - X - X - 100$,其中 X 为隐层单元的个数。本文一共做了三组实验,分别测试隐层单元数和训练样本数不同时候分别对 DBN 算法和本文算法的识别结果的影响。

1) 实验一 隐层单元的个数对 DBN 性能的影响。

DBN 分类数据的准确性在于学习的好坏,即网络参数训练的好坏。Hinton^[9]指出,DBN 的各层隐藏单元的个数应当保持一致,这样就保证了贪婪学习算法能够提高网络的性能。因此本文设置两层隐藏单元个数始终保持一样。如果隐藏层单元太少,网络就无法进行训练,如果刚好能训练,则网络的鲁棒性差,抗噪声能力较差,不能识别之前没有遇到的模式。但是如果隐层单元数过多,会导致整个模型过于庞大,能力过强,具有了所有的模式而无法接受新的模式。伴随而来的是为成倍增长的时间和内存,这种现象就是所谓的过拟合^[21]。

首先测试隐藏单元数不同时 DBN 算法的性能。选取每类样本为 5 时,测试隐藏层个数分别为 500,1000,1500,2000,2500 时候的识别率。由于每次都随机初始化网络参数,导致每次训练出的结果不尽然相同。所以,对于每一次实验都运行 10 次,取其平均值作为最终结果。实验结果如表 1 所示。训练时间 t_1 是训练样本输入网络后,经无监督预训练和有监督训练的总时间;分类时间 t_2 是测试样本输入网络后分类的时间;总时间 t ,顾名思义,即训练时间和测试时间之和:

$$t = t_1 + t_2 \quad (9)$$

其中 t_1 , t_2 均以秒为单位。

2) 实验二 隐层单元数量对本文算法性能的影响。

在本实验中,测试隐藏单元数对本文所提算法的影响。实验结果如表 2 所示。

比较比较表 2 和表 1,我们可以看出,隐层单元数为 500,1000,1500 的时候,本文算法的识别率均比 DBN 的识别率高。在隐藏层为 500 的时候,识别率提高得最多。但是在 2000 以后,本文算法的识别率下降得比 DBN 的快,训练时间

也随着增加了很多。分析原因可能是,隐藏层单元数不足的时候,提升小波提取的特征有助于模型识别图像的本质,但是随着隐藏层单元数的增加,过拟合现象也提前出现,导致网络性能变差。

抛开过拟合现象不谈,我们得出结论,提升小波提取的特征相对于像素级图像,当作为 DBN 输入时能更好地代表掌纹图像信息,更有利于深度网络学习。

表 1 隐藏层单元数不同时 DBN 的识别率

隐藏层单元个数	识别率	训练时间/s	测试时间/s	总时间/s
500	0.7536	67.0428	0.0412	67.0840
1000	0.8212	154.2335	0.0824	154.3159
1500	0.8526	287.7955	0.1514	287.9469
2000	0.8703	471.0993	0.23133	471.3104
2500	0.8684	657.3050	0.2809	657.5858

表 2 隐藏层单元数不同时本文算法的识别率

隐藏层单元个数	识别率/s	训练时间/s	测试时间/s	总时间/s
500	0.7947	60.6160	0.0383	60.65437
1000	0.8476	179.8664	0.0801	179.9503
1500	0.8668	310.7715	0.1218	310.9691
2000	0.8580	515.3482	0.1796	515.5278
2500	0.8313	823.9576	0.2803	824.2379

3) 实验三,训练样本数量对算法性能的影响。

在掌纹识别中,训练样本为整个识别过程提供分类的依据,通常是训练样本数越多则能够提取的判别性特征就越多,用来分类的依据就越充足,对识别阶段的测试就越有利。在本实验中分别测试 DBN 和本文算法在样本为 1,3,5 时候的识别率,以及传统的

LBP、PCA 算法的识别率。其中,PCA 算法提取的特征维数为总阈值的 80%,LBP 算法中设置分块数为 2,以直方图统计特征来进行识别。由于隐藏层单元数超过 1500 后,本文算法过拟合现象提前出现,故 DBN 和本文算法选隐藏层单元数为 1500。表 3 中分别列出 DBN 和本文算法 10 次实验的结果。

表 3 训练样本数不同时不同算法的识别率

样本为 1	样本为 3	样本为 5
0.4733	0.6757	0.7940
0.5489	0.6929	0.7800
0.6522	0.7957	0.8480
0.6544	0.7814	0.8560
0.6578	0.7857	0.8320
0.6600	0.7871	0.8680
0.6467	0.7900	0.8600

样本为 1	样本为 3	样本为 5
0.6456	0.7628	0.8600
0.6400	0.7871	0.8520
0.6533	0.7900	0.8480
0.6467	0.7800	0.8500
0.6511	0.7714	0.8520
0.6508	0.7831	0.8526
0.6756	0.7929	0.8740
0.6833	0.8057	0.8620
0.6878	0.8029	0.8680
0.7033	0.7971	0.8640
0.6767	0.7929	0.8640
0.7011	0.8200	0.8740
0.7022	0.8114	0.8620
0.6989	0.7929	0.8680
0.6733	0.8129	0.8600
0.6967	0.8029	0.8720
0.6899	0.8031	0.8668

由表 3 可知,PCA 和 LBP 在训练样本数较少的时候,提取的类别特征的能力并不强。随着训练样本数的增加,提取到的类别特征也随之增加,识别率也随之提高。而深度学习模型经过非监督预训练,学习到良好的网络参数,为之后的有监督训练提供了良好的起点,在测试阶段只需要用少量的训练样本进行有监督训练,就能获得较高的识别率。验证了深度学习算法能从少量的样本中学习到图像的本质特征的说法。同时,由表 3 也说明了本文算法较单纯的基于像素级的深度学习算法的识别效果更好。

5 结束语

本文提出提升小波变换和 DBN 相结合的掌纹识别,在北京交通大学的掌纹库上实验结果表明,本文算法能够自下而上自动提取掌纹图像的有效特征。经实验证明,DBN 从少量样本中提取特征的能力远高于传统算法,而本文算法将提升小波变换与 DBN 模型相结合,弥补 DBN 学习不到掌纹图像细节特征的缺陷,识别结果明显优于 DBN,在样本为 1 的时候尤为明显,识别率提高了 3.19%。

参考文献:

[1] J G Lee, J Han, K Y Whang. Trajectory clustering: A partition – and group framework [C]. Proceedings of the 2007 ACM SIGMOD international conference on Management of data, Beijing China, June 11 – 14, 2007.

[2] 岳峰,左旺孟,张大鹏. 掌纹识别算法综述[J]. 自动化学报, 2010:36(3): 353 – 356.

(下转第 360 页)

- [4] 任远芳,等. 基于 PCA-RBF 的信息安全风险评估模型[J]. 计算机仿真 2014 31(6): 212-216.
- [5] 侯佳音,史淳樵. 网络信息安全问题研究及防护策略设计与研究[J]. 电子设计工程 2015 23(22): 158-160.
- [6] 成科,等. 基于 GA 参数优化的 t-SVR 网络安全风险评估方法[J]. 计算机工程与应用 2014 50(12): 91-95.
- [7] 鲁颖欣,王健,齐宏卓. 模糊判断在网络安全风险评估中的应用研究[J]. 哈尔滨理工大学学报 2014 19(1): 36-39.
- [8] 梁磊. 基于模糊层次分析法的物流网络安全风险评估[J]. 物流技术 2015 34(5): 274-277.

- [9] 陈建莉. 基于未确知数学的网络安全风险评估模型[J]. 空军工程大学学报(自然科学版) 2014 15(2): 91-94.
- [10] 张树伟,刘文芬,王君. 节点相关的网络安全风险量化评估方法[J]. 信息工程大学学报 2015 16(2): 145-151.



[作者简介]

张俊林(1978-),男(汉族),安徽涡阳人,硕士研究生,讲师,主要研究方向:网络安全。

(上接第 342 页)

- [3] Lu Guangming, David Zhang, Wang Kuanquan. Palmprint recognition using eigenpalm Features [J]. Pattern Recognition Letters, 2003(24): 1463-1467.
- [4] Wu Xiangqian, David Zhang, Wang Kuanquan. Fisherpalms based palmprint recognition [J]. Pattern Recognition Letters, 2003, (24): 2829-12.
- [5] Lin Ling. Palmprint Identification Using PCA Algorithm and Hierarchical Neural Network [J]. Life System Modeling and Intelligent Computing Lecture Notes in Computer Science Volume 6330, 2010: 618-625.
- [6] Yi Pu, Tian Jianwu, Xu Dan, Zhang Xuejie. Palmprint recognition based on RBK-means and Hierarchical SVM [C]. International Conference on Machine Learning and Cybernetics, 66th, Hong Kong, 19-22 August 2007.
- [7] Y Bengio. Learning deep architectures for AI [J]. Foundations and Trends in Machine Learning 2009 2(1): 1-12.
- [8] G Hinton, S Osindero, Y Teh. A fast learning algorithm for deep belief nets [J]. Neural Computation 2006 18(7): 1527-1554.
- [9] Y O Bengio, Delalleau. On the expressive power of deep architectures [C]. Proc of 14th International Conference on Discovery Science [C]. Berlin: Springer Verlag, 2011: 18-36.
- [10] Y Lecun, K Kavukcuoglu, Farabet C. Convolutional networks and applications in vision [C]. IEEE International Symposium on Circuits and Systems, 2010.
- [11] A Krizhevsky, I Sutskever, G. Hinton. ImageNet classification with deep convolutional neural networks [J]. Advances in Neural Information Processing Systems 2012.
- [12] 胡昭华,宋耀良. 基于 Autoencoder 网络的数据降维和重构 [J]. 电子与信息学报 2009 31(5): 1189-1192.
- [13] G W Cottrell. New life for neural networks [J]. Science 2006, 313(5786): 454-455.
- [14] G W Talar, G E Hinton, S T Roweis. Modeling human motion using binary latent variables [C]. Advances in Neural Information Processing System 2007: 1345-1352.

- [15] Luo Ping, Wang Xiaogang, Tang Xiaou. Hierarchical face parsing via deep learning [J]. IEEE. 2012: 2480.
- [16] A Itamar, C R Derek, P K Thomas. Deep machine learning - a new frontier [J]. Artificial Intelligence Research IEEE Computational Intelligence Magazine 2010 5(4): 13-18.
- [17] K Seonjoo, L Dongjae, K Jaihei. Algorithm for detection and Elimination of false minutia in finger print images [C]. In: Audio and Video Based Biometric - Person Authentication, Third International Conference, AVBPA 2001 [C]. Halmstad, Sweden, 2001: 235-240.
- [18] 林堪甚少,宋巨龙,宋国乡. 一种新的基于提升多小波变换的图像融合方法 [J]. 信号处理 2006 10(10): 716-718.
- [19] G Huang, H Lee, Learned-Miller. Learning hierarchical representations for face verification with convolutional deep belief networks [C]. CVPR 2012: Proceedings of the 2012 IEEE Conference on Computer Vision and Pattern Recognition, Piscataway: IEEE, 2012: 2518-2525.
- [20] M A Carreira, Perpignan and G E Hinton. On constrastive divergence learning [J]. Artificial Intelligence and Statistics 2005.
- [21] 李俭川. 神经网络在除噪技术中的应用 [J]. 电子技术应用, 1999 25(12): 6-9.
- [22] Geoffrey Hinton. A practical guide to training restricted boltzman machines [DB]. <http://learning.cs.toronto.edu>. 2010. 8.



[作者简介]

赵丹丹(1991-),女(汉族),河南省郑州市人,硕士研究生,主要研究领域为图像处理与模式识别。

潘新(1974-),女(汉族),山东省即墨县人,副教授,硕士研究生导师,主要研究领域为图像处理与模式识别(通讯作者)。

刘霞(1961-),女(汉族),内蒙古呼和浩特市人,教授,主要研究方向为数据库应用与数据挖掘。

邵晓晶(1978-),女(汉族),河北平山县人,副教授,主要研究方向为图像处理。